

Raport Końcowy — Etap 4

Projekt: Analiza i przewidywanie cen samochodów używanych w Polsce

Grupa: 6 | Gr1 | 2025/2026

Członkowie: Denis Bichler, Kasper Borecki, Paweł Angielczyk, Jakub Wierzbicki

1. Cel projektu

Celem projektu było stworzenie systemu przewidującego ceny używanych samochodów na podstawie parametrów technicznych oraz danych opisowych pojazdu. Projekt wykorzystuje model transformerowy DistilBERT do regresji ceny.

2. Opis aplikacji i funkcjonalności

Aplikacja umożliwia przetwarzanie danych samochodów do postaci tekstowej, tokenizację danych, trening modelu DistilBERT oraz predykcję cen pojazdów. Model został zaimplementowany z użyciem biblioteki HuggingFace Transformers.

3. Źródło i opis danych

Dataset zawiera dane używanych samochodów w Polsce, takie jak marka, rok produkcji, przebieg, pojemność silnika, rodzaj paliwa oraz województwo. Dane zostały podzielone na zbiór treningowy i testowy w proporcji 80/20.

4. Architektura modelu

W projekcie wykorzystano model distilbert-base-uncased. Model został rozszerzony o głowicę regresyjną przewidującą wartość ciągłą reprezentującą cenę samochodu.

5. Pipeline projektu

Pipeline obejmuje preprocessing danych, serializację rekordów do tekstu, tokenizację z użyciem AutoTokenizer, fine-tuning modelu DistilBERT oraz ewaluację modelu.

6. Konfiguracja treningu

Do treningu wykorzystano optimizer AdamW z learning rate $2e-5$, batch size 8 oraz 3 epoki treningowe. Do ewaluacji wykorzystano RMSE, MAE oraz współczynnik R^2 .

7. Analiza wyników

Model osiągnął wyniki porównywalne do klasycznych modeli machine learning takich jak Random Forest i XGBoost. Transformery dobrze radzą sobie z reprezentacją danych tabelarycznych po serializacji do tekstu.

8. Ograniczenia projektu

Model transformerowy wymaga dużych zasobów obliczeniowych oraz dłuższego czasu treningu. Serializacja danych liczbowych do tekstu może prowadzić do utraty części informacji numerycznej.

9. Instrukcja uruchomienia

1. Zainstalować wymagane biblioteki:

```
pip install -r requirements.txt
```

2. Umieścić dataset w folderze data/

3. Uruchomić:

```
python main.py
```

10. Reprodukacja wyników

Projekt można odtworzyć poprzez uruchomienie notebooka

notebooks/model_training.ipynb lub skryptu train.py. Wszystkie wymagane biblioteki zostały umieszczone w requirements.txt.

11. Wnioski

Model DistilBERT okazał się skutecznym rozwiązaniem dla problemu przewidywania cen samochodów. Projekt pokazuje możliwość wykorzystania modeli NLP do analizy danych tabelarycznych.

Model	RMSE	MAE	R^2
Linear Regression	38707	17500	0.784
Random Forest	28204	12500	0.885
XGBoost	27622	12351	0.890
DistilBERT	< 28000	-	> 0.88